


GENERACIÓN DE CARAS HUMANAS

Integrantes:

- Isa Valladolid
- Maria Salome
- Ivanna Camerota



Generación de rostros humanos desde un espacio latente

Curso: DeepLearning

Institución: ITESO

Profesor: Ivan Reyes

Fecha: 02/03/26

ABSTRACT

En este trabajo desarrollamos un sistema de generación de rostros humanos utilizando un Variational Autoencoder (VAE). El objetivo principal fue aprender representaciones latentes de imágenes de caras humanas y generar nuevas imágenes a partir de dichas representaciones. Nuestro modelo fue entrenado con imágenes de resolución 128x128 utilizando una arquitectura convolucional profunda compuesta por un encoder, un espacio latente de dimensión 128 y un decoder basado en convoluciones transpuestas. Los resultados muestran que el modelo logra reconstrucciones coherentes y es capaz de generar nuevas caras plausibles a partir de muestras aleatorias del espacio latente.

INTRODUCCIÓN

La generación de imágenes mediante modelos generativos es uno de los problemas más interesantes dentro del campo del aprendizaje profundo. Los rostros humanos presentan una dificultad particular debido a su complejidad estructural y a la sensibilidad del ojo humano frente a pequeñas inconsistencias visuales.




RETO DE GENERAR DESDE UN ESPACIO LATENTE

El objetivo central de este proyecto fue aprender una representación compacta de rostros humanos dentro de un espacio latente continuo. En este espacio, cada punto representa una posible cara generada por el modelo.

METODOLOGÍA

La arquitectura utilizada corresponde a un Variational Autoencoder compuesto por tres componentes principales: encoder, espacio latente y decoder.

Arquitectura general



DATASET

El dataset utilizado consiste en un conjunto de imágenes de rostros humanos preprocesadas a una resolución de 128x128 píxeles.



PREPROCESAMIENTO

Las imágenes fueron normalizadas al rango $[0,1]$ y convertidas al tipo float32 para garantizar estabilidad durante el entrenamiento.

ARQUITECTURA DEL ENCODER

El encoder utiliza múltiples capas convolucionales para reducir progresivamente la dimensionalidad de las imágenes hasta obtener una representación latente.

Capa	Output	Parámetros	
-----	-----	-----	
Conv2D	64x64x32	896	
Conv2D	32x32x64	18,496	
Conv2D	16x16x128	73,856	
Conv2D	8x8x256	295,168	

Flatten	16384	—	
Dense	256	4,194,560	
Dense (z_mean)	128	32,896	
Dense (z_log_var)	128	32,896	

ESPACIO LATENTE

El espacio latente tiene dimensión 128 y representa una distribución gaussiana parametrizada por media y varianza.

ARQUITECTURA DEL DECODER

El decoder reconstruye la imagen original a partir de un vector latente utilizando convoluciones transpuestas.

Capa	Output	
-----	-----	
Dense	16384	
Reshape	8x8x256	
ConvTranspose	16x16x256	
ConvTranspose	32x32x128	
ConvTranspose	64x64x64	
ConvTranspose	128x128x32	
Conv2D (final)	128x128x3	

ARQUITECTURA COMPLETA




FORMULACIÓN MATEMÁTICA DEL VAE

La función de pérdida del Variational Autoencoder se compone de dos términos: la pérdida de reconstrucción y la divergencia de Kullback-Leibler.

ENTRENAMIENTO DEL MODELO


El modelo fue entrenado durante 15 épocas utilizando el optimizador Adam con batch size de 32.




RESULTADOS

Evaluamos el desempeño del modelo mediante reconstrucción de imágenes y generación de nuevas muestras desde el espacio latente.

1/1 ————— 0s 383ms/step



1/1 ————— 0s 48ms/step



EVALUACIÓN CUANTITATIVA

La métrica utilizada fue el Mean Squared Error (MSE) entre las imágenes originales y las reconstruidas.

Capa	Output
-----	-----
Dense	16384
Reshape	8x8x256
ConvTranspose	16x16x256
ConvTranspose	32x32x128
ConvTranspose	64x64x64
ConvTranspose	128x128x32
Conv2D (final)	128x128x3

NUESTRA INTEGRACIÓN

Durante el desarrollo del proyecto integramos diferentes tareas para lograr una implementación completa del modelo generativo.

CONCLUSIONES

Los resultados obtenidos demuestran que el modelo VAE es capaz de aprender representaciones latentes coherentes de rostros humanos y generar nuevas imágenes plausibles. Considerando la complejidad inherente de las caras humanas, el desempeño obtenido puede considerarse altamente satisfactorio.

En conclusión, el modelo funcionó sorprendentemente bien para lo complejas que son las caras humanas.